

Поиск архитектуры смеси экспертов с использованием суррогатной функции.

П. К. Бабкин¹

¹Московский физико-технический институт (национальный исследовательский университет)

Задача автоматического поиска архитектуры нейронной сети важна в области машинного обучения, так как избавляет от тяжелого ручного подбора архитектуры, который требует экспертных знаний и многих усилий. Эта задача поставлена давно и хорошо изучена.

Параллельно с появлением решения задачи автоматического поиска архитектуры, происходило развитие подхода смеси экспертов. Смесь экспертов – это способ построения нейронной сети, при котором входное значение модели направляется определенной подсети в соответствии с ответом роутера (gating network).

Наше исследование посвящено разработке метода поиска архитектуры для смеси экспертов, то есть подбору оптимальной структуры для каждого из отдельно взятых экспертов и определению алгоритма маршрутизации. В литературе существуют исследования, которые также посвящены этой теме, но мы подходим к задаче с более аналитической стороны и предлагаем свой теоретически обоснованный подход.

Задачу поиска архитектуры для смеси экспертов можно формально поставить следующим образом:

$$\prod_{n=1}^N \sum_{k=1}^K p(y_i, i \in C_k | x_i, \alpha_k, \theta_k) \rightarrow \max_{\alpha_1, \dots, \alpha_K, \theta_1, \dots, \theta_K},$$

где для k -ого эксперта C_k – индексы элементов датасета, на которых он работает, α_k – архитектура, соответствующая этому эксперту, θ_k – параметры этой архитектуры после обучения. Для решения этой задачи мы используем суррогатную функцию, которая оценивает эффективность определенной архитектуры при работе на данных, соответствующих некоторому кластеру. Суррогатная функция помогает оценивать правдоподобие исходя из формулы:

$$p(y_i, i \in C_k | x_i, \alpha_k, \theta_k) = p(i \in C_k) p(y_i | x_i, \alpha_k, \theta_k, i \in C_k) = r_{ik} u(\alpha_k, R_k),$$

где r_{ik} – вероятность того, что i -ый элемент описывается k -ым экспертом и $R_k = \{r_{ik} | i = 1, \dots, N\}$.

Суррогатная функция обучается на предварительно составленном датасете из архитектур и точности, которые эти архитектуры показывают на определенном кластере датасета. Таким образом задача принимает следующий вид:

$$\prod_{n=1}^N \sum_{k=1}^K r_{ik} u(\alpha_k, R_k) \rightarrow \max_{\alpha_1, \dots, \alpha_K, R_1, \dots, R_K}$$

В работе доказывается теорема о том, как применять ЕМ алгоритм для максимизации данного правдоподобия. В результате составляется алгоритм максимизации правдоподобия, который является основным результатом нашей статьи.

Предложенный метод тестируется на синтетических данных, где показано, что алгоритм корректно восстанавливает исходное разбиение выборки и подбирает архитектуры, адаптированные под структуру данных. Полученные результаты подтверждают применимость предложенного подхода для задач автоматизированного проектирования смесей нейросетевых экспертов.

Литература

1. Chen Z. [et al.]. Towards understanding mixture of experts in deep learning // arXiv preprint arXiv:2208.02813. 2022.

2. *Jiang L.* [et al.]. AutoMoE. Heterogeneous mixture-of-experts with adaptive computation for efficient neural machine translation // Findings of the Association for Computational Linguistics: ACL 2023. – 2023. – C. 9116-9132.
3. *Piwko J.* [et al.]. Divide, specialize, and route: a new approach to efficient ensemble learning //arXiv preprint arXiv:2506.20814. – 2025.