

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ФИЗИКО-ТЕХНИЧЕСКИЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)»

Бабкин Пётр

**ПОИСК АРХИТЕКТУРЫ МОДЕЛИ СМЕСИ
ЭКСПЕРТОВ С УЧЁТОМ КЛАСТЕРНОЙ
СТРУКТУРЫ ДАННЫХ**

Специальность 09.04.01 —
«Информатика и вычислительная техника»

Выпускная квалификационная работа магистра

Научный руководитель:
Бахтеев О.Ю.

Москва 2026

Содержание

	Стр.
Введение	3
Глава 1. Постановка задачи	6
1.1 Пространство поиска архитектур	6
1.2 Модель смеси экспертов	6
1.3 Кластеризация данных и маршрутизация	7
1.4 Целевая функция	7
Глава 2. Метод	9
2.1 Суррогатная функция	9
2.2 Суррогатно-ассистированный обобщённый EM (SGEM)	10
2.3 Анализ сходимости	12
Глава 3. Вычислительный эксперимент	16
3.1 Модельная задача	16
3.2 Смесь CIFAR-100 и SVHN	17
Заключение	23
Список литературы	25
Глава А. Доказательство теоремы о сходимости	29
А.1 Вспомогательные леммы	29
А.2 Основное доказательство	31
А.3 Скорость сходимости	32
Глава Б. Дополнительные результаты экспериментов	33
Б.1 Декомпозиция точности при кластерном шлюзе	33
Б.2 Чувствительность к весу балансировки нагрузки	34

Введение

Модель смеси экспертов (Mixture-of-Experts, MoE) — это композитная модель, в которой вход распределяется механизмом маршрутизации (gating) между несколькими специализированными подмоделями-экспертами, а итоговый ответ формируется как взвешенная комбинация их выходов [1–3]. Случаи, когда эксперты являются классическими статистическими моделями, хорошо изучены в литературе [4], в частности, когда эксперты заданы логистическими регрессиями [5] или гауссовскими моделями [6; 7]. В последние годы, с ростом интереса к нейронным сетям, конструкция MoE была перенесена на архитектуры глубокого обучения [8]. Высокая вычислительная эффективность достигается за счёт разреженной маршрутизации, когда вход направляется лишь к небольшому фиксированному числу экспертов [9–11]; особенно широкое распространение MoE получили в трансформерных моделях, где размер модели играет ключевую роль [12–15].

Параллельно методы поиска нейросетевой архитектуры (Neural Architecture Search, NAS) развились в самостоятельную, хорошо изученную область [16–18]. Цель NAS — автоматический выбор оптимальной архитектуры из широкого множества кандидатов, что снимает необходимость в ручном подборе и экспертных знаниях [19]. Сложились две основные парадигмы. Первая — вычислительно затратный многократный (many-shot) поиск с несколькими циклами обучения и последующим выбором кандидата методами обучения с подкреплением [20; 21] или эволюционными алгоритмами [22; 23]. Вторая — одношаговый (one-shot) поиск, где обучается единая суперсеть, а затем из неё выбирается оптимальная подсеть [19; 24; 25].

Несмотря на успехи обеих методологий по отдельности, применение методов NAS именно к архитектурам MoE остаётся слабо исследованной областью. В отличие от классического подхода, в котором все эксперты имеют *одинаковую* архитектуру [11], в настоящей работе допускается *архитектурная гетерогенность* экспертов. Мы полагаем, что такая гибкость повышает эффективность итоговой модели, позволяя каждому эксперту специализироваться под свой тип данных. Близкие по постановке работы

немногочисленны: в [26] быстрая МоЕ-архитектура ищется эволюционно с наследованием весов из суперсети; в [27] строится фреймворк для эффективного инференса МоЕ под конкретное оборудование; наиболее близкая к нашей работа [28] варьирует число экспертов в слоях. В отличие от неё, мы оптимизируем сами архитектуры экспертов, а не только их количество.

Архитектура МоЕ по своей природе хорошо подходит для данных с выраженной кластерной структурой. Существуют теоретические работы, показывающие на относительно простых примерах справедливость этого утверждения [29], а практические исследования демонстрируют эффективность МоЕ на мультимодальных датасетах [30–32]. Тем не менее, механизмы, благодаря которым эксперты выравниваются с различными модальностями данных, изучены недостаточно.

В связи с этим формулируется следующий исследовательский вопрос: *как организовать условия, при которых архитектуры экспертов адаптируются под конкретные кластеры данных?* В настоящей работе предлагается фреймворк структурно-зависимого поиска архитектуры (Structure-Aware NAS, SA-NAS), который совместно определяет архитектуры экспертов и разбиение кластеров данных между ними. Ключевыми элементами метода являются суррогатная модель, предсказывающая качество архитектуры на заданном подмножестве данных без её фактического обучения, и алгоритм оптимизации правдоподобия смеси на основе обобщённого ЕМ-алгоритма с адаптивно уточняемым суррогатом (Surrogate-assisted Generalized EM, SGEM).

Основные результаты работы.

- **Постановка задачи.** Предложена новая постановка задачи поиска архитектуры для модели смеси экспертов как задачи максимизации кластерно-зависимого правдоподобия; дано её теоретическое обоснование — показана эквивалентность оценке максимального правдоподобия по неполным данным для латентной модели смеси.
- **Алгоритм.** Предложен алгоритм решения поставленной задачи, основанный на ЕМ-алгоритме с адаптивно уточняемой суррогатной моделью.

- **Гарантия сходимости.** Для предложенного алгоритма доказана теорема о сходимости (Теорема 1).
- **Датасеты и эксперименты.** Построены датасеты, на которых у подходов на основе смеси экспертов есть явное преимущество, и на них проведены сравнительные эксперименты с базовыми методами.

Обозначения. Жирными строчными буквами $\mathbf{y}$ обозначаются векторы, жирными прописными $\mathbf{X}$ — матрицы. Рассматривается задача обучения с учителем: задан датасет $\mathcal{D} = (\mathbf{X}, \mathbf{y})$, где $\mathbf{X}$ — матрица признаков, $\mathbf{y}$ — вектор целевых переменных. Данные разбиты на обучающую и валидационную подвыборки, для которых заданы функции потерь $\mathcal{L}_{\text{train}}$ и $\mathcal{L}_{\text{val}}$ соответственно. Индекс $n \in \{1, \dots, N\}$ нумерует объекты, $m \in \{1, \dots, M\}$ — кластеры данных, $k \in \{1, \dots, K\}$ — экспертов.

1. Постановка задачи

1.1 Пространство поиска архитектур

Каждый эксперт представляет собой свёрточную сеть, собранную из *ячейки* (cell) — ориентированного ациклического графа, вершины которого являются вычислительными узлами. Мы используем принятое в реализации кодирование ячейки: ячейка содержит фиксированное число узлов, и каждый узел применяет одну операцию из конечного множества $\mathcal{O}$ (свёртки с разными размерами ядра, пулинг, тождественное преобразование) к выходу одного из предшествующих узлов; первый узел читает вход ячейки. Таким образом, архитектура полностью задаётся двумя дискретными выборами для каждого узла — *какая* операция применяется и *в какой* узел она направляется, то есть какой из предыдущих узлов подаётся ей на вход. Все эти выборы собираются в единый вектор архитектуры α , так что α описывает одну конкретную ячейку. Поскольку и множество $\mathcal{O}$, и число узлов конечны, пространство поиска $\mathcal{A}$ всех допустимых α конечно, а поиск архитектуры сводится к выбору наилучшего $\alpha \in \mathcal{A}$. Для архитектуры α_k с обученными параметрами θ_k соответствующую нейронную сеть обозначим $f(\alpha_k, \theta_k) : \mathcal{X} \rightarrow \mathcal{Y}$.

1.2 Модель смеси экспертов

Модель смеси экспертов объединяет K таких сетей, каждая из которых призвана специализироваться на своей области входного пространства. Обозначив через $\alpha = [\alpha_1^\top, \dots, \alpha_K^\top]^\top$ конкатенацию архитектур экспертов, прогноз МоЕ записывается как взвешенная по маршрутизации комбинация выходов экспертов

$$g(\alpha, \theta, w_r)(x) = \sum_{k=1}^K r_k(x, w_r) f(\alpha_k, \theta_k)(x), \quad (1.1)$$

где значения шлюза $r_k(\mathbf{x}, \mathbf{w}_r) \geq 0$, $\sum_{k=1}^K r_k = 1$, вырабатываются маршрутизирующей сетью с параметрами $\mathbf{w}_r$.

1.3 Кластеризация данных и маршрутизация

Перед поиском архитектуры датасет разбивается на M кластеров $\mathcal{D} = \mathcal{C}_1 \cup \dots \cup \mathcal{C}_M$, каждый из которых группирует объекты схожей структуры (например, семантический класс или модальность данных). Обозначим через $\mathcal{C}_m \subseteq \{1, \dots, N\}$ индексы объектов кластера m , а через $m(n)$ — номер кластера объекта n . Маршрутизация задаётся на уровне кластеров: пусть $r_{mk} \in [0, 1]$ — вероятность приписывания кластера m эксперту k , $\sum_{k=1}^K r_{mk} = 1$; эти величины собираются в матрицу маршрутизации $\mathbf{R} \in [0, 1]^{M \times K}$, а её столбец $\mathbf{r}_k = \mathbf{R}_{:,k}$ кодирует кластеры, за которые отвечает эксперт k . Итоговое жёсткое разбиение восстанавливается как $I_k = \{m : \arg \max_{k'} r_{mk'} = k\}$.

В отличие от стандартного обучения МоЕ, где при фиксированной архитектуре обучаются лишь параметры шлюза, здесь *нахождение маршрутизации $\mathbf{R}$ само является частью поиска архитектуры*: наилучшая архитектура эксперта зависит от того, на каком подмножестве кластеров он обучается, что связывает выбор архитектуры со специализацией под данные.

1.4 Целевая функция

Поиск архитектуры МоЕ формулируется как задача максимизации правдоподобия. Требуется выбрать для каждого эксперта k архитектуру α_k , её параметры θ_k и множество кластеров I_k , за которое он отвечает, так

чтобы максимизировать правдоподобие данных под смесью:

$$\prod_{n=1}^N \sum_{k=1}^K p(y_n, m(n) \in I_k \mid x_n, \boldsymbol{\alpha}_k, \boldsymbol{\theta}_k) \rightarrow \max_{\boldsymbol{\alpha}_{1:K}, \boldsymbol{\theta}_{1:K}, I_{1:K}}. \quad (1.2)$$

Каждое слагаемое распадается на вероятность маршрутизации и условное правдоподобие: $p(y_n, m(n) \in I_k \mid \dots) = p(m(n) \in I_k) p(y_n \mid x_n, \boldsymbol{\alpha}_k, \boldsymbol{\theta}_k, m(n) \in I_k)$, где вероятность принадлежности есть в точности кластерная маршрутизация $p(m(n) \in I_k) = r_{m(n),k}$.

Прямое вычисление условного множителя требует фактического обучения сети, что вычислительно неприемлемо. Поэтому вводится *суррогатная функция*

$$u : \mathcal{A} \times [0,1]^M \rightarrow \mathbb{R}_{\geq 0}, \quad u(\boldsymbol{\alpha}_k, \mathbf{r}_k) \approx -\frac{1}{|\mathcal{D}_{\mathbf{r}_k}^{\text{val}}|} \sum_{n \in \mathcal{D}_{\mathbf{r}_k}^{\text{val}}} \log p(y_n \mid x_n, \boldsymbol{\alpha}_k, \boldsymbol{\theta}_k^*), \quad (1.3)$$

которая предсказывает *среднюю по объектам кросс-энтропийную ошибку* архитектуры $\boldsymbol{\alpha}_k$, обученной на подмножестве кластеров, заданном вектором $\mathbf{r}_k$. Суррогат считается постоянным внутри кластера, поэтому для каждого $n \in \mathcal{C}_m$, приписанного эксперту k , $p(y_n \mid x_n, \boldsymbol{\alpha}_k, \boldsymbol{\theta}_k, m(n) \in I_k) \approx e^{-u(\boldsymbol{\alpha}_k, \mathbf{r}_k)}$.

Подставляя эти выражения в (1.2), логарифмируя и группируя N пообъектных слагаемых по кластерам (внутри кластера маршрутизация и суррогат одинаковы), получаем *кластерно-зависимую целевую функцию*:

$$\mathcal{J}(\boldsymbol{\alpha}_{1:K}, \mathbf{R}) = \sum_{m=1}^M |\mathcal{C}_m| \log \sum_{k=1}^K r_{mk} e^{-u(\boldsymbol{\alpha}_k, \mathbf{r}_k)} \rightarrow \max_{\boldsymbol{\alpha}_{1:K}, \mathbf{R}}. \quad (1.4)$$

Здесь r_{mk} задаёт степень приписывания кластера m эксперту k , множитель $e^{-u(\boldsymbol{\alpha}_k, \mathbf{r}_k)}$ есть пообъектное правдоподобие, достигаемое экспертом k на своём подмножестве, а вес $|\mathcal{C}_m|$ отражает вклад кластера, пропорциональный его размеру. Задача (1.4) решается алгоритмом, описанным в главе 2.

2. Метод

2.1 Суррогатная функция

Прямая оптимизация задачи (1.2) требует многократного обучения нейронных сетей для множества кандидатов-архитектур, что непомерно дорого в случае МоЕ, где каждая оценка уже включает K сетей. Чтобы преодолеть это узкое место, точное обучение заменяется обученной суррогатной моделью.




Рисунок 2.1 — Схема метода: суррогатная модель u используется для подбора наиболее подходящих архитектур экспертов для каждого кластера данных.

Пусть обучающие данные разбиты на M кластеров, и для $\mathbf{b} \in \{0, 1\}^M$ пусть $\mathcal{D}_{\mathbf{b}} = \bigcup_{m: b_m=1} \mathcal{C}_m$ — подмножество кластеров, выбранное вектором $\mathbf{b}$. Суррогатная функция $u(\boldsymbol{\alpha}, \mathbf{b})$ предсказывает среднюю по объектам кросс-энтропийную ошибку (отрицательное среднее лог-правдоподобие верного класса) архитектуры $\boldsymbol{\alpha}$, обученной на $\mathcal{D}_{\mathbf{b}}$, без проведения фактического обучения; это та же величина, что входит в объектив (1.4) через $e^{-u(\boldsymbol{\alpha}_k, \mathbf{r}_k)}$.

Суррогат обучается на датасете пар «архитектура–подмножество», собранных реальным обучением, $\mathcal{D}_{\text{sur}} = \{(\boldsymbol{\alpha}^{(i)}, \mathbf{b}^{(i)}, y^{(i)})\}_{i=1}^{N_s}$, где $y^{(i)}$ — измеренная валидационная кросс-энтропия. Модель $u_{\boldsymbol{\theta}}$ параметризуется гра-

фовой нейронной сетью (GNN), кодирующей граф архитектуры, конкатенированной с эмбедингом кластерной маски $\mathbf{b}$; минимизируется средне-квадратичная ошибка

$$\min_{\theta} \frac{1}{|\mathcal{D}_{\text{surr}}|} \sum_{(\alpha, \mathbf{b}, y) \in \mathcal{D}_{\text{surr}}} (u_{\theta}(\alpha, \mathbf{b}) - y)^2. \quad (2.1)$$

Суррогат уточняется в цикле активного обучения. На каждой итерации с помощью Monte-Carlo dropout получают предсказательное среднее $\mu(\alpha, \mathbf{b})$ и стандартное отклонение $\sigma(\alpha, \mathbf{b})$ по T стохастическим прогнозам, после чего кандидаты оцениваются по нижней доверительной границе $\text{LCB} = \mu - \sigma$ (поскольку u — ошибка, перспективны кандидаты с наименьшим предсказанным значением и высокой эпистемической неопределённостью). Наиболее перспективный кандидат обучается с нуля, полученная тройка добавляется в $\mathcal{D}_{\text{surr}}$, и суррогат переобучается. Существенно, что u_{θ} обучается *только на дискретных* масках $\mathbf{b}$, поэтому дифференцируемая оптимизация должна сочетаться с релаксацией дискретных входов.

2.2 Суррогатно-ассистированный обобщённый ЕМ (SGEM)

Рассмотрение маршрутизации «кластер–эксперт» как латентной переменной превращает объектив (1.4) в модель смеси, к которой напрямую применим ЕМ-алгоритм, причём суррогат $u^{(t)}$ заменяет труднодоступное истинное качество эксперта.

Латентная форма целевой функции. Для каждого объекта n введём унитарный (one-hot) латентный вектор $\mathbf{z}_n \in \{0,1\}^K$, где $z_{nk} = 1$ тогда и только тогда, когда объект n порождён экспертом k , и соберём их в матрицу $\mathbf{Z} = \|\mathbf{z}_n\|$. Порождающая история стандартна для смеси: эксперт объекта n выбирается из маршрутизации его кластера, $p(z_{nk} = 1) = r_{m(n),k}$, а метка порождается с пообъектным правдоподобием эксперта $e^{-u(\alpha_k, \mathbf{r}_k)}$.

Тогда правдоподобие полных данных есть

$$p(\mathbf{y}, \mathbf{Z} \mid \boldsymbol{\alpha}_{1:K}, \mathbf{R}) = \prod_{n=1}^N \prod_{k=1}^K \left(r_{m(n),k} e^{-u(\boldsymbol{\alpha}_k, \mathbf{r}_k)} \right)^{z_{nk}}, \quad (2.2)$$

где роль весов смеси играет маршрутизация r_{mk} , а роль пообъектного правдоподобия компоненты — $e^{-u(\boldsymbol{\alpha}_k, \mathbf{r}_k)}$.

Эквивалентность с (1.4). Каждая строка $\mathbf{z}_n$ унитарна, поэтому маргинализация сворачивает внутреннее произведение в сумму; так как маршрутизация и суррогат постоянны внутри кластера, группировка $|\mathcal{C}_m|$ одинаковых множителей даёт $p(\mathbf{y} \mid \boldsymbol{\alpha}_{1:K}, \mathbf{R}) = \prod_m \left(\sum_k r_{mk} e^{-u(\boldsymbol{\alpha}_k, \mathbf{r}_k)} \right)^{|\mathcal{C}_m|}$, логарифм чего в точности равен $\mathcal{J}(\boldsymbol{\alpha}_{1:K}, \mathbf{R})$ из (1.4). Таким образом, максимизация объектива (1.4) есть оценка максимального правдоподобия для латентной модели (2.2), которую мы решаем ЕМ-алгоритмом.

Е-шаг. При фиксированных $(\boldsymbol{\alpha}_{1:K}, \mathbf{R})$ апостериорное распределение факторизуется по объектам, а ответственность эксперта k за кластер m есть нормированный вес смеси

$$q_{mk} = \frac{r_{mk} e^{-u(\boldsymbol{\alpha}_k, \mathbf{r}_k)}}{\sum_{j=1}^K r_{mj} e^{-u(\boldsymbol{\alpha}_j, \mathbf{r}_j)}}, \quad \sum_{k=1}^K q_{mk} = 1. \quad (2.3)$$

Интуитивно, кластер мягко приписывается к экспертам, которые и претендуют на него (r_{mk} велико), и предсказанно хорошо его моделируют ($u(\boldsymbol{\alpha}_k, \mathbf{r}_k)$ мало).

М-шаг. Подстановка апостериора в математическое ожидание лог-правдоподобия полных данных и группировка по кластерам дают Q -функцию

$$Q(\boldsymbol{\alpha}_{1:K}, \mathbf{R}) = \sum_{m=1}^M |\mathcal{C}_m| \sum_{k=1}^K q_{mk} [\log r_{mk} - u(\boldsymbol{\alpha}_k, \mathbf{r}_k)], \quad (2.4)$$

которая максимизируется по маршрутизации $\mathbf{R}$ и архитектурам $\boldsymbol{\alpha}_{1:K}$. Два блока обновляются поочерёдно.

М-шаг по маршрутизации. При фиксированных архитектурах Q максимизируется по $\mathbf{R}$ (при ограничении $\sum_k r_{mk} = 1$) градиентным подъёмом по логитам маршрутизации с использованием straight-through Gumbel-

Softmax для проброса градиента через дискретные маски $\mathbf{r}_k$, которые потребляет суррогат. Слагаемое $\sum_{m,k} |\mathcal{C}_m| q_{mk} \log r_{mk}$ есть кросс-энтропия, чей условный оптимум $r_{mk} = q_{mk}$ подтягивает маршрутизацию к текущим ответственностям, а слагаемое $-q_{mk} u(\boldsymbol{\alpha}_k, \mathbf{r}_k)$ дополнительно смещает столбец $\mathbf{r}_k$ к маскам, на которых эксперт предсказанно хорош.

М-шаг по архитектурам. При фиксированной маршрутизации зависящая от архитектуры часть (2.4) есть $-\sum_m |\mathcal{C}_m| q_{mk} u(\boldsymbol{\alpha}_k, \mathbf{r}_k)$, поэтому каждый эксперт оптимизируется независимо *минимизацией* своей взвешенной ответственностями суррогатной ошибки. Так как u недифференцируема по $\boldsymbol{\alpha}$, кандидаты-архитектуры сэмплируются из пространства поиска, и для каждого эксперта k оставляется кандидат с наименьшим $u(\boldsymbol{\alpha}_k, \mathbf{r}_k)$.

Алгоритм SGEM суммируется следующей процедурой. Вход: суррогат u_θ , пространство поиска $\mathcal{A}$, число экспертов K , число кластеров M , число итераций T .

1. Инициализировать архитектуры $\boldsymbol{\alpha}_1, \dots, \boldsymbol{\alpha}_K$ случайно и логиты маршрутизации $\boldsymbol{\ell} \in \mathbb{R}^{M \times K} \sim \mathcal{N}(\mathbf{0}, I)$.
2. Для $t = 1, \dots, T$ повторять:
 - (a) *E-шаг*: вычислить ответственности q_{mk} по (2.3);
 - (b) *М-шаг по R*: градиентный подъём по (2.4) с Gumbel-Softmax;
 - (c) *М-шаг по α*: для каждого эксперта сэмплировать кандидатов и оставить с наименьшим $u(\cdot, \mathbf{r}_k)$;
 - (d) *Шаг активного обучения*: обучить выбранных кандидатов, пополнить $\mathcal{D}_{\text{sur}}$, переобучить u_θ .
3. Вернуть $\boldsymbol{\alpha}_{1:K}$ и жёсткое назначение $\hat{r}_{mk} = [k = \arg \max_{k'} r_{mk'}]$.

2.3 Анализ сходимости

Особенность Алгоритма SGEM в том, что суррогат $u^{(t)}$, используемый на Е- и М-шагах, сам обновляется между итерациями, поэтому классический аргумент монотонности ЕМ [33;34] напрямую неприменим. Покажем,

что при достаточно быстром убывании ошибки суррогата SGEM сходится в том же смысле, что и обобщённый ЕМ.

Пусть u_{true} — неизвестная истинная ошибка эксперта (пообъектная кросс-энтропия архитектуры α , обученной на подмножестве $\mathbf{r}$). Определим пошаговую ошибку суррогата в шкале потерь

$$\varepsilon_t = \sup_{\alpha \in \mathcal{A}, \mathbf{r} \in [0,1]^M} |u^{(t)}(\alpha, \mathbf{r}) - u_{\text{true}}(\alpha, \mathbf{r})|. \quad (2.5)$$

Параметр $\theta = (\alpha_{1:K}, \mathbf{R})$ лежит в компактном множестве $\Theta = \mathcal{A}^K \times (\Delta_K)^M$; обозначим $N = \sum_m |\mathcal{C}_m|$. Истинное (взвешенное по размерам кластеров) лог-правдоподобие есть

$$L_{\text{true}}(\theta) = \sum_{m=1}^M |\mathcal{C}_m| \log \sum_{k=1}^K r_{mk} e^{-u_{\text{true}}(\alpha_k, \mathbf{r}_k)}, \quad (2.6)$$

а истинная Q -функция —

$$Q_{\text{true}}(\theta; \theta') = \sum_{m=1}^M |\mathcal{C}_m| \sum_{k=1}^K w_{mk}(\theta') [\log r_{mk} - u_{\text{true}}(\alpha_k, \mathbf{r}_k)], \quad (2.7)$$

где $w_{mk}(\theta')$ — ответственности, вычисленные при u_{true} . Введём вариационную свободную энергию, параметризованную функцией потерь u :

$$\mathcal{F}_u(q, \theta) = \sum_{m=1}^M |\mathcal{C}_m| \sum_{k=1}^K q_{mk} \log \frac{r_{mk} e^{-u(\alpha_k, \mathbf{r}_k)}}{q_{mk}}, \quad L_u(\theta) = \max_q \mathcal{F}_u(q, \theta).$$

Предположение 1. Существует $U_{\max} < \infty$ такое, что $0 \leq u_{\text{true}}, u^{(t)} \leq U_{\max}$ для всех $\alpha, \mathbf{r}, t$.

Предположение 2. Ошибки суррогата суммируемы: $\sum_{t=0}^{\infty} \varepsilon_t < \infty$.

Предположение 3. M -шаг обобщён, т.е. для каждого t возвращается $\theta^{(t+1)}$ с $\mathcal{F}_{u^{(t)}}(q^{(t)}, \theta^{(t+1)}) \geq \mathcal{F}_{u^{(t)}}(q^{(t)}, \theta^{(t)})$.

Предположение 4. Для каждого α отображение $\mathbf{r} \mapsto u_{\text{true}}(\alpha, \mathbf{r})$ непрерывно на $[0,1]^M$.

Теорема 1 (Сходимость SGEM с адаптивным суррогатом). *При выполнении Предположений 1–4 последовательность $\{\theta^{(t)}\}$, порождаемая Алгоритмом SGEM, удовлетворяет:*

- (а) *последовательность $\{L_{\text{true}}(\theta^{(t)})\}$ сходится;*
- (б) *всякая предельная точка θ^* является стационарной точкой L_{true} на Θ в смысле $Q_{\text{true}}(\theta; \theta^*) \leq Q_{\text{true}}(\theta^*; \theta^*)$ для всех $\theta \in \Theta$.*

Схема доказательства. Ключевые шаги следующие. Из вариационного представления $L_u(\theta) = \max_q \mathcal{F}_u(q, \theta)$ с максимумом в точке $q_{mk}^* \propto r_{mk} e^{-u(\alpha_k, \mathbf{r}_k)}$ следует равномерная оценка отклонения: $|\mathcal{F}_{u_{\text{true}}}(q, \theta) - \mathcal{F}_{u^{(t)}}(q, \theta)| \leq N\varepsilon_t$ и, как следствие, $|L_{\text{true}}(\theta) - L^{(t)}(\theta)| \leq N\varepsilon_t$. Объединяя это с Предположением 3 (подъём свободной энергии на М-шаге) и равенством на Е-шаге, получаем *квазимонотонность*

$$L_{\text{true}}(\theta^{(t+1)}) \geq L_{\text{true}}(\theta^{(t)}) - 2N\varepsilon_t. \quad (2.8)$$

Положив $V_t = L_{\text{max}} - L_{\text{true}}(\theta^{(t)}) \geq 0$ (величина $L_{\text{max}} = \sup_{\theta} L_{\text{true}}$ конечна ввиду компактности Θ), из (2.8) имеем $V_{t+1} \leq V_t + 2N\varepsilon_t$ при $\sum_t 2N\varepsilon_t < \infty$. По теореме Роббинса–Зигмунда [35] последовательность $\{V_t\}$ сходится, что доказывает (а). Для (б) используется устойчивость softmax-ответственности к возмущению суррогата: при $\varepsilon_t \rightarrow 0$ ответственности и Q -функция, вычисленные при $u^{(t)}$, сходятся к истинным; если бы предельная точка не была стационарной, нашёлся бы θ' с $Q_{\text{true}}(\theta'; \theta^*) - Q_{\text{true}}(\theta^*; \theta^*) = \delta > 0$, что по переходу через $\tilde{Q}^{(t)}$ и подъёму на М-шаге дало бы прирост $\Delta_t \geq \delta/8$ для бесконечного числа t , противоречащий суммируемости из (а). Следовательно, θ^* стационарна. $\square$

Побочным следствием доказательства пункта (а) является явная оценка скорости

$$L_{\text{true}}(\theta^*) - L_{\text{true}}(\theta^{(T)}) \leq 2N \sum_{t=T}^{\infty} \varepsilon_t.$$

Если $\varepsilon_t = O(t^{-p})$ при $p > 1$, то $L_{\text{true}}(\theta^{(T)}) \rightarrow L_{\text{true}}(\theta^*)$ со скоростью $O(T^{1-p})$, что согласуется со скоростями, наблюдаемыми в анализе стохастического ЕМ [36].

Замечание 1. Предположение суммируемости 2 — суррогатный аналог условия убывающего шага в стохастическом ЕМ; ослабление его до $\varepsilon_t \rightarrow 0$ сохраняет пункт (b), но не пункт (a). На практике суммируемость достигается, когда шаг активного обучения обеспечивает достаточно полное покрытие пространства $\mathcal{A} \times [0,1]^M$.

Новизна и связь с классическими результатами о сходимости. Классическая теория сходимости ЕМ и его обобщённого варианта [33; 34] опирается на монотонный подъём единого *фиксированного* правдоподобия: каждый М-шаг не уменьшает одну и ту же целевую функцию, и сходимость следует из монотонной ограниченной последовательности. В нашей постановке эта предпосылка нарушена. Поскольку качество эксперта берётся с адаптивно переобучаемого суррогата $u^{(t)}$, а не из точного обучения, оптимизируемая на итерации t цель сама является «движущейся мишенью», а истинное правдоподобие L_{true} , которое нас в итоге интересует, алгоритмом *никогда* не вычисляется. Поэтому точная монотонность недоступна, и стандартный аргумент неприменим.

Теорема 1 показывает, что сходимость тем не менее сохраняется, — в этом состоит основной теоретический вклад. Механизм — *квази-монотонность* $L_{\text{true}}(\theta^{(t+1)}) \geq L_{\text{true}}(\theta^{(t)}) - 2N\varepsilon_t$: истинное правдоподобие может проседать, но лишь на величину, пропорциональную пошаговой ошибке суррогата ε_t . Суммируемость этих ошибок превращает $\{L_{\text{true}}(\theta^{(t)})\}$ в почти-супермартингал, и аргумент Роббинса–Зигмунда [35] даёт и сходимость, и стационарность всякой предельной точки *истинной* цели — хотя каждый Е- и М-шаг видит только суррогат.

Это отличается от анализа стохастического и онлайн-ЕМ [36], где возмущение точного шага ЕМ — *нулевое в среднем стохастическое* (от Монте-Карло Е-шага), гасимое убывающим шагом. В нашем случае возмущение — наоборот, *детерминированная ограниченная ошибка аппроксимации* обученного суррогата, а роль убывающего шага играет условие суммируемости 2, малость которого обеспечивается не усреднением шума, а покрытием пространства поиска при активном обучении. Насколько нам известно, это первая гарантия сходимости для ЕМ-подобной процедуры архитектурного поиска, чья пошаговая цель задаётся *адаптивно обучаемой* суррогатной моделью.

3. Вычислительный эксперимент

Метод проверяется на двух взаимодополняющих задачах: (i) контролируемой двумерной модельной задаче, позволяющей проверить, совпадает ли восстановленная маршрутизация с истинной кластерной структурой, и (ii) разнородном бенчмарке на основе смеси CIFAR-100 и SVHN, где проводится сравнение с базовыми методами.

3.1 Модельная задача

Сэмплируются 2000 точек в $\mathbb{R}^2$ из задачи на четыре класса, состоящей из одного «линейного» облака (два класса, разделённые диагональю) и одного «кольцевого» облака (два класса — внутреннее и внешнее кольцо). Данные делятся 80/20 на обучение и валидацию и кластеризуются на $M = 20$ кластеров методом KMeans. Берётся $K = 2$ эксперта, так что идеальное решение однозначно: один эксперт должен специализироваться на линейном облаке, другой — на кольцевом. Пространство поиска — небольшое cell-пространство над двумерными входами, чьё множество операций намеренно подобрано так, чтобы два облака предпочитали *разные* архитектуры. В частности, оно содержит *линейную* операцию $\mathbf{x} \mapsto W\mathbf{x}$, которой уже достаточно для разделения линейно-разделимого облака (два класса делятся прямой диагональю), и операцию *радиальной базисной функции* (RBF) $\mathbf{x} \mapsto \exp(-\gamma \|\mathbf{x} - \mathbf{c}\|^2)$, кодирующую расстояние до центра $\mathbf{c}$ и естественно подходящую кольцевому облаку, чьи два класса (внутреннее и внешнее кольцо) разделяются радиусом, а не гиперплоскостью; несколько вспомогательных операций (тождество, поэлементный квадрат, сдвиг, ReLU, dropout) дополняют множество. Поскольку чисто линейная архитектура не моделирует концентрические кольца, а RBF-доминированная избыточно плоха на линейном облаке, оптимальная смесь вынуждена назначить *архитектурно различных* экспертов двум областям; тем самым

модельная задача проверяет именно архитектурную специализацию, а не только маршрутизацию.

С параметрами, приведёнными в журнале экспериментов, SGEM восстанавливает *идеальное* разбиение кластеров (10, 10) между двумя экспертами за 20 ЕМ-итераций, совпадающее с эталонным разбиением по координате центроида (рис. 3.1). Эта проверка подтверждает, что суррогатный объектив (1.4) корректно поставлен и что предложенный оптимизатор решает его при достаточно точном суррогате, в согласии с Теоремой 1.




Рисунок 3.1 — Модельная задача. (а) Датасет на четыре класса: линейное облако (классы 0–1) и кольцевое облако (классы 2–3). (б) $M = 20$ KMeans-кластеров (кресты — центроиды). (с) Разбиение экспертов, восстановленное SGEM при $K = 2$: кластеры делятся точно по границе линейное/кольцевое облако, совпадая с эталонным разбиением с точностью до перестановки меток экспертов.

3.2 Смесь CIFAR-100 и SVHN

Чтобы проверить, восстанавливает ли кластерно-зависимый объектив осмысленное разбиение данных на реалистичных данных, строится разнородный бенчмарк смешиванием CIFAR-100 и SVHN в равной пропорции (всего 42 000 изображений). Метки SVHN сдвинуты на 100, так что объединённая задача содержит 110 классов. Два источника образуют максимально разделённую доменную структуру, задающую корректный эталон: при $K = 2$ идеальная маршрутизация приписывает каждый кластер эксперту, специализированному на его источнике. Данные разбиваются на

$M = 30$ *семантических* кластеров, полученных предобученным экстрактором признаков, с трёхчастным разбиением обучение/валидация/тест (0.7/0.15/0.15). Итоговый эталон содержит 19 CIFAR-мажоритарных и 11 SVHN-мажоритарных кластеров со средней чистотой источника 0.978.

Все конфигурации МоЕ используют $K = 2$ эксперта. Базовая сеть — малая DARTS-подобная архитектура **CIFAR100Net** (stem, две обычные ячейки, фиксированная редуцирующая ячейка, global average pooling, полносвязная голова). МоЕ-обёртка инстанцирует K таких сетей, объединённых фиксированным жёстким *кластерным шлюзом*: каждый кластер направляется одному эксперту, так что шлюз напрямую отражает обнаруженное разбиение. Поиск архитектуры использует разбиение обучение/валидация; итоговая модель дообучается 100 эпох на обучение $\cup$ валидация и оценивается *однократно* на отложенном тесте.

Балансировка нагрузки. Без регуляризации динамика ЕМ склонна схлопывать все кластеры на одного эксперта — это свойство самого объекта. При жёсткой маршрутизации, когда каждый кластер m направляется единственному эксперту $k(m)$, внутренняя сумма в (1.4) имеет лишь одно слагаемое, и логарифм гасит экспоненту:

$$\mathcal{J} = - \sum_{k=1}^K N_k u_k, \quad N_k = \sum_{m: k(m)=k} |\mathcal{C}_m|, \quad (3.1)$$

где $u_k = u(\boldsymbol{\alpha}_k, \mathbf{r}_k)$ — предсказанная ошибка эксперта k , а N_k — число направленных ему объектов. Если суррогат почти постоянен по своему аргументу-маршрутизации и эксперты взаимозаменяемы ($u_k \equiv \bar{u}$), то $\mathcal{J} = -\bar{u} N$ не зависит от разбиения $\{N_k\}$; а если u_k различны, то $\mathcal{J}$ линейна по N_k и максимизируется отправкой всех кластеров одному эксперту с наименьшим u_k . Чтобы этому противодействовать, М-шаг дополняется штрафом балансировки

$$\text{LB}(\mathbf{R}) = K \cdot \sum_{k=1}^K \bar{r}_k \cdot p_k, \quad \bar{r}_k = \frac{1}{M} \sum_{m=1}^M r_{mk}, \quad p_k = \frac{|\{m : \arg \max_{k'} r_{mk'} = k\}|}{M}, \quad (3.2)$$

с весом λ_{LB} ; он минимален при равномерной маршрутизации. Поскольку правильное доменное разбиение само несбалансировано (19/11), агрессив-

ный штраф уводил бы маршрутизацию *от* него, поэтому λ_{LB} удерживается малым ($\lambda_{LB} = 1$), а схлопывание предотвращается схемой сбора данных, описанной ниже. Приложение [Б.2](#) делает этот компромисс количественным, локализуя точку перелома $\lambda_{LB} \approx 3.77$, за которой балансируемое — и потому доменно-слепое — разбиение уже выигрывает по пенализованному объективу.

Честный сбор данных. Ранняя версия пайплайна достигала лишь ≈ 0.59 точности при почти случайном восстановлении источника ($\approx 60\%$), что было вызвано двумя дефектами построения датасета суррогата, а не оптимизатором ЕМ. Во-первых, каждая кандидат-архитектура оценивалась на *всей* валидации, а не на области своих кластеров, поэтому эксперт, обученный на чистом SVHN, оценивался частично на изображениях CIFAR и выглядел плохим; это схлопывало разрыв предсказанных ошибок между специализированным и смешанным экспертом. Ограничение оценки кластерами самого эксперта (оценка по области) устраняет смещение. Во-вторых, кластерные маски для обучения суррогата сэмплировались включением каждого кластера независимо с вероятностью $1/2$, так что почти чистые односторонние подмножества практически не возникали; замена этого *логравномерным* сэмплером по размеру маски делает малые, часто почти чистые подмножества частыми — без обращения к меткам источника. С обоими исправлениями и $\lambda_{LB} = 1$ SGEM восстанавливает доменную структуру самостоятельно.

Результаты приведены в таблице [1](#). При честном сборе данных SGEM достигает точности 0.6199 ± 0.009 , превосходя как DARTS $\times K$ (0.5913), так и базовый Random-MoE (0.5467) на +2.9 и +7.3 процентных пункта, и оказываясь в пределах 1.3 п.п. от оракульного MoE (0.6327), которому *дано* истинное разбиение по источнику. Именно кластерный шлюз выделяет качество маршрутизации: при обучаемом шлюзе методы становятся почти неразличимы (все ≈ 0.63), так как обучаемый шлюз способен компенсировать неоптимальное разбиение. Более тонкий ablation, раскладывающий эту точность на вклад маршрутизации и архитектуры, приведён в Приложении [Б.1](#): выигрыш почти полностью обусловлен маршрутизацией кластер→эксперт, тогда как архитектурная гетерогенность экспертов при уже правильной маршрутизации добавляет мало, а обучение маршрутиза-

ции внутри SGEM (а не её фиксация) как раз и восстанавливает доменную структуру.

Таблица 1 — Точность на тесте для смеси CIFAR-100 / SVHN с кластерным шлюзом ($M = 30$, $K = 2$, семантическая кластеризация, среднее $\pm$ std.). Оракульный МоЕ использует истинное разбиение по источнику и является верхней границей, а не конкурентом.

Метод	точность (кластерный шлюз)	сидов
Random-MoE	0.5467 ± 0.029	4
DARTS $\times K$ (одна арх.)	0.5913 ± 0.009	5
SGEM (наш)	0.6199 ± 0.009	3
Оракульный МоЕ (<i>метки источника</i>)	0.6327 ± 0.004	3

Поскольку эталонное разбиение по источнику резкое (средняя чистота 0.978), можно напрямую проверить, согласуется ли с ним обученная маршрутизация. По трём сидам жёсткое назначение SGEM теперь совпадает с эталонным доменным разбиением на $92\% \pm 2\%$ кластеров (наилучшая из двух перестановок меток) — намного выше $\approx 54\%$ сбалансированного случайного разбиения и значительно лучше $\approx 60\%$ ранней смещённой версии. В типичном прогоне (рис. 3.3) один эксперт становится *чистым* CIFAR-специалистом (17 кластеров, без SVHN), а другой собирает все 11 SVHN-кластеров вместе лишь с 2 CIFAR. Таким образом, кластерно-зависимый объектив *действительно* обнаруживает доменную структуру данных на этом бенчмарке без использования меток источника.

Сходимость. На рис. 3.2 прослежен один прогон SGEM по ЕМ-итерациям. Взвешенный по размерам объектив $L^{(t)}$ растёт с точностью до шума оптимизации, а доля совпадения с источником поднимается с 67% до 100%, эмпирически иллюстрируя сходимость, гарантированную Теоремой 1. Пики двух кривых расходятся на одну итерацию (объектив на $t = 8$, восстановление на $t = 9$) — тот же рассинхрон объектива и качества у оптимума, что отмечен выше.




Рисунок 3.2 — Сходимость SGEM на смеси CIFAR-100/SVHN (seed 322).

Левая ось (синяя): совпадение жёсткой маршрутизации с эталонным разбиением по источнику; пунктир — уровень случайного разбиения 54%.

Правая ось (красная): взвешенный по размерам объектив $L^{(t)}$. Обе величины растут по ЕМ-итерациям, доля совпадения достигает 100% на

$$t = 9.$$



Рисунок 3.3 — Представители кластеров смеси CIFAR-100 / SVHN при маршрутизации SGEM ($K = 2$; показаны первые 15 из $M = 30$ семантических кластеров). Каждая строка — один кластер: левый столбец — медоид кластера, остальные — восемь ближайших к среднему изображений. Рамка медоида окрашена по эксперту, которому SGEM приписывает кластер (E0 — SVHN-специалист, красный; E1 — CIFAR-специалист, зелёный). SGEM направляет все SVHN-кластеры (изображения цифр) эксперту E0 и сохраняет E1 чистым CIFAR-экспертом; доля совпадения с источником для этого прогона — 93%.

Заключение

В работе предложен фреймворк SA-NAS — структурно-зависимый поиск архитектуры для моделей смеси экспертов, связывающий поиск архитектур отдельных экспертов с кластерной структурой данных. Фреймворк опирается на графовую нейросетевую суррогатную модель, предсказывающую качество архитектуры по её описанию и бинарной кластерной маске и обучаемую в цикле активного обучения с оценкой неопределённости по Monte-Carlo dropout. Кластерно-зависимый объектив оптимизируется алгоритмом SGEM, рассматривающим маршрутизацию как латентную переменную; доказана его сходимость при адаптивно уточняемом суррогате (Теорема 1).

На контролируемой модельной задаче ЕМ-вариант восстанавливает идеальное разбиение линейное/кольцевое облако при $K = 2$ экспертах, подтверждая корректность постановки при надёжном суррогате. На намеренно разнородной смеси CIFAR-100 / SVHN, чьи истинные домены задают резкий эталон, SGEM восстанавливает это разбиение на 92% кластеров *без использования меток источника*: один эксперт специализируется на чистой CIFAR-подзадаче, другой собирает SVHN-кластеры. При полученном жёстком кластерном шлюзе достигается точность 0.620 на тесте — выше базового Random-MoE (0.547) и K копий одной DARTS-архитектуры (0.591) и в пределах 1.3 п.п. от оракульного MoE (0.633), которому передано истинное разбиение. Решающую роль здесь сыграл диагностический анализ: ранний пайплайн, оценивавший экспертов на всей валидации и сэмплирувавший кластерные маски равномерно, никогда не показывал суррогату почти чистые подмножества и схлопывал маршрутизацию, тогда как оценка по области эксперта вместе с доменно-агностичным логравномерным сэмплером масок устраняет это смещение и позволяет кластерно-зависимому объективу обнаружить структуру данных самостоятельно.

Результаты получены на двухдоменном бенчмарке при $K = 2$ и умеренном числе сидов; естественным продолжением являются расширение на большее число доменов, большие K и более широкий набор сидов. Дальнейшие направления — масштабирование пространства поиска, перенос фрейм-

ворка на трансформерные МоЕ-слои, а также усиление теории кластерно-зависимого объектива, в частности учёт штрафа балансировки нагрузки в гарантии сходимости.

Список литературы

1. Adaptive mixtures of local experts / Robert A Jacobs, Michael I Jordan, Steven J Nowlan, Geoffrey E Hinton // *Neural computation*. — 1991. — Vol. 3, no. 1. — Pp. 79–87.
2. *Jordan Michael I, Jacobs Robert A*. Hierarchical mixtures of experts and the EM algorithm // *Neural computation*. — 1994. — Vol. 6, no. 2. — Pp. 181–214.
3. *Jacobs Robert A, Peng Fengchun, Tanner Martin A*. A Bayesian approach to model selection in hierarchical mixtures-of-experts architectures // *Neural Networks*. — 1997. — Vol. 10, no. 2. — Pp. 231–241.
4. Divide, Specialize, and Route: A New Approach to Efficient Ensemble Learning / Jakub Piwko, Jędrzej Ruciński, Dawid Płudowski et al. // *arXiv preprint arXiv:2506.20814*. — 2025.
5. A general theory for softmax gating multinomial logistic mixture of experts / Huy Nguyen, Pedram Akbarian, TrungTin Nguyen, Nhat Ho // *arXiv preprint arXiv:2310.14188*. — 2023.
6. *Nguyen Huy, Nguyen TrungTin, Ho Nhat*. Demystifying softmax gating function in Gaussian mixture of experts // *Advances in Neural Information Processing Systems*. — 2023. — Vol. 36. — Pp. 4624–4652.
7. *Rasmussen Carl, Ghahramani Zoubin*. Infinite mixtures of Gaussian process experts // *Advances in neural information processing systems*. — 2001. — Vol. 14.
8. *Eigen David, Ranzato Marc'Aurelio, Sutskever Ilya*. Learning factored representations in a deep mixture of experts // *arXiv preprint arXiv:1312.4314*. — 2013.
9. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer / Noam Shazeer, Azalia Mirhoseini, Krzysztof Maziarczyk et al. // *arXiv preprint arXiv:1701.06538*. — 2017.

10. Scaling vision with sparse mixture of experts / Carlos Riquelme, Joan Puigcerver, Basil Mustafa et al. // *Advances in Neural Information Processing Systems*. — 2021. — Vol. 34. — Pp. 8583–8595.
11. *Fedus William, Zoph Barret, Shazeer Noam*. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity // *Journal of Machine Learning Research*. — 2022. — Vol. 23, no. 120. — Pp. 1–39.
12. Mixtral of experts / Albert Q Jiang, Alexandre Sablayrolles, Antoine Roux et al. // *arXiv preprint arXiv:2401.04088*. — 2024.
13. Demons in the detail: On implementing load balancing loss for training specialized mixture-of-expert models / Zihan Qiu, Zeyu Huang, Bo Zheng et al. // *arXiv preprint arXiv:2501.11873*. — 2025.
14. Deepseekmoe: Towards ultimate expert specialization in mixture-of-experts language models / Damai Dai, Chengqi Deng, Chenggang Zhao et al. // *arXiv preprint arXiv:2401.06066*. — 2024.
15. *Mu Siyuan, Lin Sen*. A comprehensive survey of mixture-of-experts: Algorithms, theory, and applications // *arXiv preprint arXiv:2503.07137*. — 2025.
16. A comprehensive survey of neural architecture search: Challenges and solutions / Pengzhen Ren, Yun Xiao, Xiaojun Chang et al. // *ACM Computing Surveys (CSUR)*. — 2021. — Vol. 54, no. 4. — Pp. 1–34.
17. Xnas: Neural architecture search with expert advice / Niv Nayman, Asaf Noy, Tal Ridnik et al. // *Advances in neural information processing systems*. — 2019. — Vol. 32.
18. Learning transferable architectures for scalable image recognition / Barret Zoph, Vijay Vasudevan, Jonathon Shlens, Quoc V Le // *Proceedings of the IEEE conference on computer vision and pattern recognition*. — 2018. — Pp. 8697–8710.
19. *Liu Hanxiao, Simonyan Karen, Yang Yiming*. Darts: Differentiable architecture search // *arXiv preprint arXiv:1806.09055*. — 2018.

20. *Zoph Barret, Le Quoc V.* Neural architecture search with reinforcement learning // *arXiv preprint arXiv:1611.01578*. — 2016.
21. Designing neural network architectures using reinforcement learning / Bowen Baker, Otkrist Gupta, Nikhil Naik, Ramesh Raskar // *arXiv preprint arXiv:1611.02167*. — 2016.
22. Regularized evolution for image classifier architecture search / Esteban Real, Alok Aggarwal, Yanping Huang, Quoc V Le // *Proceedings of the aaai conference on artificial intelligence*. — Vol. 33. — 2019. — Pp. 4780–4789.
23. Cars: Continuous evolution for efficient neural architecture search / Zhao-hui Yang, Yunhe Wang, Xinghao Chen et al. // *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. — 2020. — Pp. 1829–1838.
24. *Chen Xiangning, Hsieh Cho-Jui.* Stabilizing differentiable architecture search via perturbation-based regularization // *International conference on machine learning* / PMLR. — 2020. — Pp. 1554–1565.
25. Greedynas: Towards fast one-shot nas with greedy supernet / Shan You, Tao Huang, Mingmin Yang et al. // *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. — 2020. — Pp. 1999–2008.
26. Automoe: Heterogeneous mixture-of-experts with adaptive computation for efficient neural machine translation / Ganesh Jawahar, Subhabrata Mukherjee, Xiaodong Liu et al. // *arXiv preprint arXiv:2210.07535*. — 2022.
27. CMN: a co-designed neural architecture search for efficient computing-in-memory-based mixture-of-experts / Shihao Han, Sishuo Liu, Shucheng Du et al. // *Science China Information Sciences*. — 2024. — Vol. 67, no. 10. — P. 200405.
28. MoENAS: Mixture-of-Expert based Neural Architecture Search for jointly Accurate, Fair, and Robust Edge Deep Neural Networks / Lotfi Abdelkrim Mecharbat, Alberto Marchisio, Muhammad Shafique et al. // *arXiv preprint arXiv:2502.07422*. — 2025.

29. Towards understanding the mixture-of-experts layer in deep learning / Zixiang Chen, Yihe Deng, Yue Wu et al. // *Advances in neural information processing systems*. — 2022. — Vol. 35. — Pp. 23049–23062.
30. *Chai Fung Tsz, Tseung Spark C.* Mixture of experts models for multilevel data: modelling framework and approximation theory // *arXiv e-prints*. — 2022. — Pp. arXiv–2209.
31. *Guo Jiang, Shah Darsh J, Barzilay Regina.* Multi-source domain adaptation with mixture of experts // *arXiv preprint arXiv:1809.02256*. — 2018.
32. Multi-level mixture of experts for multimodal entity linking / Zhiwei Hu, Víctor Gutiérrez-Basulto, Zhiliang Xiang et al. // *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V. 2*. — 2025. — Pp. 979–990.
33. *Dempster A. P., Laird N. M., Rubin D. B.* Maximum likelihood from incomplete data via the EM algorithm // *Journal of the Royal Statistical Society, Series B*. — 1977. — Vol. 39, no. 1. — Pp. 1–38.
34. *Wu C. F. Jeff.* On the convergence properties of the EM algorithm // *The Annals of Statistics*. — 1983. — Vol. 11, no. 1. — Pp. 95–103.
35. *Robbins Herbert, Siegmund David.* A convergence theorem for non negative almost supermartingales and some applications // *Optimizing Methods in Statistics*. — Academic Press, 1971. — Pp. 233–257.
36. *Cappé Olivier, Moulines Éric.* On-line expectation–maximization algorithm for latent data models // *Journal of the Royal Statistical Society, Series B*. — 2009. — Vol. 71, no. 3. — Pp. 593–613.

А. Доказательство теоремы о сходимости

В приложении приведены вспомогательные леммы и полное доказательство Теоремы 1. Используются обозначения раздела 2.3: $\theta = (\alpha_{1:K}, \mathbf{R}) \in \Theta = \mathcal{A}^K \times (\Delta_K)^M$ при конечном $\mathcal{A}$, ε_t — пошаговая ошибка суррогата (в шкале потерь, см. (2.5)), $N = \sum_m |\mathcal{C}_m|$, а вариационная свободная энергия, параметризованная функцией потерь u , есть

$$\mathcal{F}_u(q, \theta) = \sum_{m=1}^M |\mathcal{C}_m| \sum_{k=1}^K q_{mk} \log \frac{r_{mk} e^{-u(\alpha_k, \mathbf{r}_k)}}{q_{mk}}.$$

Обозначим $L_u(\theta) = \max_q \mathcal{F}_u(q, \theta)$ — взвешенное по размерам лог-правдоподобие, порождённое потерей u , и сократим $L_{\text{true}} = L_{u_{\text{true}}}$, $L^{(t)} = L_{u^{(t)}}$.

А.1 Вспомогательные леммы

Утверждение 1 (Максимизация ELBO). *Для всякой функции потерь $u : \mathcal{A} \times [0, 1]^M \rightarrow \mathbb{R}_{\geq 0}$ и всякого $\theta \in \Theta$ выполнено $L_u(\theta) = \max_q \mathcal{F}_u(q, \theta)$, причём максимум достигается в*

$$q_{mk}^*(\theta) = \frac{r_{mk} e^{-u(\alpha_k, \mathbf{r}_k)}}{\sum_j r_{mj} e^{-u(\alpha_j, \mathbf{r}_j)}}.$$

Доказательство. Зафиксируем θ и m . Множитель $|\mathcal{C}_m|$ положителен и выносится из внутренней максимизации по $q_{m,:}$, не влияя на оптимум. Обозначив $a_{mk} = r_{mk} e^{-u(\alpha_k, \mathbf{r}_k)}$ и используя $\sum_k q_{mk} = 1$, внутреннее выражение равно $-\text{KL}(q_{m,:} \| a_{m,:} / \sum_j a_{mj}) + \log \sum_j a_{mj}$. KL-дивергенция неотрицательна и обращается в нуль в точности при $q_{mk} = a_{mk} / \sum_j a_{mj}$, что даёт утверждение. Суммирование по m с весами $|\mathcal{C}_m|$ восстанавливает $L_u(\theta) = \sum_m |\mathcal{C}_m| \log \sum_k a_{mk}$. $\square$

Следствием является разложение Нила–Хинтона $L_u(\theta) = \mathcal{F}_u(q, \theta) + \sum_m |\mathcal{C}_m| \text{KL}(q_{m,:} \| q_{m,:}^*(\theta))$, откуда $L_u(\theta) \geq \mathcal{F}_u(q, \theta)$ с равенством тогда и только тогда, когда $q = q^*(\theta)$.

Лемма 1 (Равномерное отклонение ELBO). *При Предположении 1 для всех q, θ, t выполнено $|\mathcal{F}_{u_{\text{true}}}(q, \theta) - \mathcal{F}_{u^{(t)}}(q, \theta)| \leq N \varepsilon_t$.*

Доказательство. Слагаемые $\log r_{mk}$ и $-\log q_{mk}$ сокращаются между двумя ELBO, оставляя $\mathcal{F}_{u_{\text{true}}} - \mathcal{F}_{u^{(t)}} = \sum_m |\mathcal{C}_m| \sum_k q_{mk} [u^{(t)}(\alpha_k, \mathbf{r}_k) - u_{\text{true}}(\alpha_k, \mathbf{r}_k)]$. Оценивая скобку через ε_t и используя $\sum_k q_{mk} = 1$, получаем $|\mathcal{F}_{u_{\text{true}}} - \mathcal{F}_{u^{(t)}}| \leq \varepsilon_t \sum_m |\mathcal{C}_m| = N \varepsilon_t$. $\square$

Следствие 1. *Для всякого θ выполнено $|L_{\text{true}}(\theta) - L^{(t)}(\theta)| \leq N \varepsilon_t$.*

Доказательство. Применяя Лемму 1 к максимумам двух ELBO и используя $|\max_q f - \max_q g| \leq \sup_q |f - g|$. $\square$

Для анализа предельных точек потребуются ещё три оценки — на softmax-отображение, на ответственности и на Q -функцию.

Лемма 2 (Устойчивость softmax). *Пусть $a_k, \tilde{a}_k > 0$ удовлетворяют $e^{-\varepsilon} a_k \leq \tilde{a}_k \leq e^{\varepsilon} a_k$. Тогда нормированные векторы $p_k = a_k / \sum_j a_j$ и $\tilde{p}_k = \tilde{a}_k / \sum_j \tilde{a}_j$ удовлетворяют $|\tilde{p}_k - p_k| \leq (e^{2\varepsilon} - 1) p_k \leq 3\varepsilon p_k$ при $\varepsilon \leq 1$.*

Доказательство. $\tilde{p}_k \leq a_k e^{\varepsilon} / \sum_j a_j e^{-\varepsilon} = p_k e^{2\varepsilon}$ и аналогично $\tilde{p}_k \geq p_k e^{-2\varepsilon}$. $\square$

Лемма 3 (Отклонение ответственностей). *Пусть $w_{mk}(\theta) = q_{mk}^*(\theta)$ — ответственности при истинном суррогате (Утверждение 1 при $u = u_{\text{true}}$), а $q_{mk}^{(t)}$ — ответственности E -шага на итерации t . При $\varepsilon_t \leq 1$ выполнено $|q_{mk}^{(t)} - w_{mk}(\theta^{(t)})| \leq 3\varepsilon_t w_{mk}(\theta^{(t)})$.*

Доказательство. Применяем Лемму 2 с $a_{mk} = r_{mk}^{(t)} e^{-u_{\text{true}}(\alpha_k^{(t)}, \mathbf{r}_k^{(t)})}$ и $\tilde{a}_{mk}$, полученным заменой u_{true} на $u^{(t)}$. Отношение $\tilde{a}_{mk}/a_{mk} = e^{u_{\text{true}} - u^{(t)}}$ удовлетворяет $e^{-\varepsilon_t} \leq \tilde{a}_{mk}/a_{mk} \leq e^{\varepsilon_t}$ ввиду (2.5), так что лемма применима при $\varepsilon = \varepsilon_t$. $\square$

Лемма 4 (Отклонение Q -функции). *Определим суррогатную Q -функцию $\tilde{Q}^{(t)}(\theta; \theta') = \sum_m |\mathcal{C}_m| \sum_k q_{mk}^{(t)}(\theta') [\log r_{mk} - u^{(t)}(\alpha_k, \mathbf{r}_k)]$. При Предположении 1 существует постоянная $C_Q = C_Q(N, K, U_{\text{max}})$ такая, что для всех θ, θ' и всех t с $\varepsilon_t \leq 1$ выполнено $|\tilde{Q}^{(t)}(\theta; \theta') - Q_{\text{true}}(\theta; \theta')| \leq C_Q \varepsilon_t$.*

Доказательство. Прибавим и вычтем $\sum_m |\mathcal{C}_m| \sum_k q_{mk}^{(t)} [\log r_{mk} - u_{\text{true}}(\boldsymbol{\alpha}_k, \mathbf{r}_k)]$. Первая часть (член ошибки суррогата) есть $\sum_m |\mathcal{C}_m| \sum_k q_{mk}^{(t)} (u_{\text{true}} - u^{(t)})$ и ограничена $N\varepsilon_t$. Остаток распадается на $\sum_m |\mathcal{C}_m| \sum_k (q_{mk}^{(t)} - w_{mk})(-u_{\text{true}})$ и $\sum_m |\mathcal{C}_m| \sum_k (q_{mk}^{(t)} - w_{mk}) \log r_{mk}$. Первое ограничено $3NK U_{\max} \varepsilon_t$ по Лемме 3 (так как $|u_{\text{true}}| \leq U_{\max}$). Для второго, используя $|x \log x| \leq 1/e$ на $[0,1]$ вместе с оценкой устойчивости softmax (Лемма 2), получаем оценку $3N\varepsilon_t/e$. Суммируя три вклада, приходим к утверждению с $C_Q = N(1 + 3K U_{\max} + 3/e)$. $\square$

А.2 Основное доказательство

Утверждение 2 (Квазимонотонность L_{true}). *При Предположениях 1–3 для всякого t выполнено*

$$L_{\text{true}}(\theta^{(t+1)}) \geq L_{\text{true}}(\theta^{(t)}) - 2N\varepsilon_t. \quad (\text{A.1})$$

Доказательство. Свяжем пять неравенств. Во-первых, $L_{\text{true}}(\theta^{(t+1)}) \geq \mathcal{F}_{u_{\text{true}}}(q^{(t)}, \theta^{(t+1)})$, так как $L_u(\theta) = \max_q \mathcal{F}_u(q, \theta)$. Во-вторых, по Лемме 1, $\mathcal{F}_{u_{\text{true}}}(q^{(t)}, \theta^{(t+1)}) \geq \mathcal{F}_{u^{(t)}}(q^{(t)}, \theta^{(t+1)}) - N\varepsilon_t$. В-третьих, обобщённый М-шаг (Предположение 3) даёт $\mathcal{F}_{u^{(t)}}(q^{(t)}, \theta^{(t+1)}) \geq \mathcal{F}_{u^{(t)}}(q^{(t)}, \theta^{(t)})$. В-четвёртых, Е-шаг делает последнее равным $L^{(t)}(\theta^{(t)})$. В-пятых, Следствие 1 даёт $L^{(t)}(\theta^{(t)}) \geq L_{\text{true}}(\theta^{(t)}) - N\varepsilon_t$. Объединяя пять шагов, получаем (A.1). $\square$

Часть (а): сходимость правдоподобия. Положим $L_{\max} = \sup_{\theta \in \Theta} L_{\text{true}}(\theta)$ (величина конечна ввиду компактности Θ — Предположение 4 и конечность $\mathcal{A}$). Определим $V_t = L_{\max} - L_{\text{true}}(\theta^{(t)}) \geq 0$. Из Утверждения 2 следует $V_{t+1} \leq V_t + 2N\varepsilon_t$, причём $\sum_t 2N\varepsilon_t < \infty$ по Предположению 2. По теореме Роббинса–Зигмунда [35] (с $a_t = 0$, $b_t = 2N\varepsilon_t$) последовательность $\{V_t\}$ сходится, а значит, сходится и $\{L_{\text{true}}(\theta^{(t)})\}$. $\square$

Часть (b): стационарность предельных точек.

Шаг 1: существование. Θ компактно, поэтому у $\{\theta^{(t)}\}$ есть хотя бы одна предельная точка $\theta^* = \lim_{j \rightarrow \infty} \theta^{(t_j)}$.

Шаг 2: предположение от противного. Пусть θ^* не стационарна: найдутся $\theta' \in \Theta$ и $\delta > 0$ с $Q_{\text{true}}(\theta'; \theta^*) - Q_{\text{true}}(\theta^*; \theta^*) = \delta > 0$.

Шаг 3: непрерывность. Отображение $\theta' \mapsto Q_{\text{true}}(\theta; \theta')$ непрерывно на Θ : $w_{mk}(\theta')$ непрерывно, так как u_{true} непрерывно по $\mathbf{r}$ (Предположение 4), а softmax непрерывен; произведение $w_{mk} \log r_{mk}$ непрерывно продолжается в $r_{mk} = 0$, так как $w_{mk} = O(r_{mk})$, а $r \mapsto r \log r$ непрерывно в нуле. Поэтому при достаточно больших j $Q_{\text{true}}(\theta'; \theta^{(t_j)}) - Q_{\text{true}}(\theta^{(t_j)}; \theta^{(t_j)}) \geq \delta/2$.

Шаг 4: переход к $\tilde{Q}$. По Лемме 4, $\tilde{Q}^{(t_j)}(\theta'; \theta^{(t_j)}) - \tilde{Q}^{(t_j)}(\theta^{(t_j)}; \theta^{(t_j)}) \geq \delta/2 - 2C_Q \varepsilon_{t_j} \geq \delta/4$ при достаточно больших j , так как $\varepsilon_{t_j} \rightarrow 0$.

Шаг 5: подъём на M -шаге. Поскольку M -шаг перебирает множество кандидатов, содержащее θ' (ввиду конечности $\mathcal{A}$ и свойств замыкания обновления по $\mathbf{R}$), $\tilde{Q}^{(t_j)}(\theta^{(t_j+1)}; \theta^{(t_j)}) \geq \tilde{Q}^{(t_j)}(\theta'; \theta^{(t_j)})$. Переходя обратно через Лемму 4, получаем $\Delta_{t_j} := Q_{\text{true}}(\theta^{(t_j+1)}; \theta^{(t_j)}) - Q_{\text{true}}(\theta^{(t_j)}; \theta^{(t_j)}) \geq \delta/4 - 2C_Q \varepsilon_{t_j} \geq \delta/8$ при достаточно больших j .

Шаг 6: противоречие через суммируемость. Неравенство Гиббса $L_{\text{true}}(\theta^{(t+1)}) - L_{\text{true}}(\theta^{(t)}) \geq \Delta_t$ вместе с Утверждением 2 даёт $\Delta_t \geq -2N\varepsilon_t$. Тогда неотрицательная последовательность $\Delta_t + 2N\varepsilon_t$ удовлетворяет $\sum_t (\Delta_t + 2N\varepsilon_t) < \infty$ (Роббинс–Зигмунд для V_t), и потому $\sum_t \Delta_t < \infty$. Но Шаг 5 даёт $\Delta_{t_j} \geq \delta/8$ для бесконечного числа j , откуда $\sum_t \Delta_t = +\infty$ — противоречие. Следовательно, θ^* стационарна. $\square$

А.3 Скорость сходимости

Побочным следствием доказательства части (а) является явная оценка скорости

$$L_{\text{true}}(\theta^*) - L_{\text{true}}(\theta^{(T)}) \leq 2N \sum_{t=T}^{\infty} \varepsilon_t.$$

Если $\varepsilon_t = O(t^{-p})$ при $p > 1$, то $L_{\text{true}}(\theta^{(T)}) \rightarrow L_{\text{true}}(\theta^*)$ со скоростью $O(T^{1-p})$, что согласуется со скоростями анализа стохастического ЕМ [36].

Б. Дополнительные результаты экспериментов

В приложении собраны два ablation-эксперимента на смеси CIFAR-100/SVHN ($K = 2$, $M = 30$ семантических кластеров), на которые ссылается глава 3. Все числа — точность на тесте при кластерном шлюзе (среднее $\pm$ std. по указанному числу сидов), измеренная по тому же протоколу, что и таблица 1.

Б.1 Декомпозиция точности при кластерном шлюзе

Чтобы отнести выигрыш МоЕ к двум его составляющим — маршрутизации кластер→эксперт и архитектуре экспертов, — меняем по одному фактору за раз (таблица 2). Блок (i) фиксирует одну DARTS-архитектуру (найденную на всей смеси) и меняет только маршрутизацию: переход от случайного разбиения кластеров к оракульному разбиению по источнику повышает точность на 3,0 процентных пункта, то есть маршрутизация — основной рычаг. Блок (ii) фиксирует оракульную маршрутизацию и меняет архитектуру: одна fullmix-архитектура, CIFAR-найденная и SVHN-найденная различаются в пределах 1 п.п., то есть при уже правильной маршрутизации архитектурная гетерогенность экспертов добавляет мало. Блок (iii) изолирует вклад *обучения* маршрутизации внутри SGEM: заморозка матрицы маршрутизации на случайной инициализации (без M-шага по **R**) опускает долю совпадения с источником до случайной (59%), а точность — до 0.598, тогда как полный метод восстанавливает разбиение (92%) и достигает 0.620 — по сути того же значения, что и при оракульной маршрутизации в блоке (i), но без меток источника.

Таблица 2 — Ablation, раскладывающий точность при кластерном шлюзе. «совп. с источ.» — доля совпадения жёсткой маршрутизации с эталонным разбиением по источнику; она равна 100% по построению всякий раз, когда используется оракульный сплит.

Сетап	точность	совп. с источ.
<i>(i) меняем маршрутизацию, архитектура фикс. (fullmix DARTS)</i>		
случайное разбиение	0.587 ± 0.006	$\approx 54\%$
оракульное разбиение по источнику	0.617 ± 0.007	100%
<i>(ii) меняем архитектуру, оракульная маршрутизация</i>		
fullmix-архитектура	0.627 ± 0.009	100%
CIFAR-найденная архитектура	0.636 ± 0.003	100%
SVHN-найденная архитектура	0.626 ± 0.006	100%
<i>(iii) обучаем маршрутизацию (SGEM, без меток)</i>		
маршрутизация заморожена (случайно)	0.598 ± 0.003	$59 \pm 7\%$
SGEM (полный)	0.620 ± 0.009	$92 \pm 2\%$

Б.2 Чувствительность к весу балансировки нагрузки

В главе 3 вес балансировки удерживается малым ($\lambda_{LB} = 1$), потому что правильное разбиение по источнику само несбалансировано (19/11), и сильный штраф балансировки уводил бы маршрутизацию от него. Сделаем этот компромисс количественным, оценив три кандидатных жёстких разбиения по *пенализованному* объективу $L - \lambda_{LB} \cdot LB_N$, фактически оптимизируемому на М-шаге, где пообъектные потери u_k получены реальным обучением фиксированной архитектуры на кластерах каждого эксперта (без суррогата), $L = -\sum_k N_k u_k$ — результирующий взвешенный объектив, а $LB_N = K \sum_k P_k^2 \cdot N$ — экстенсивный штраф балансировки (таблица 3).

На непенализованном объективе ($\lambda_{LB} = 0$) оракульное разбиение предпочтительнее с запасом $\Delta L = 7874$. Однако, будучи несбалансированным, оно штрафует сильнее сбалансированного на $\Delta LB_N = 2091$ на единицу λ_{LB} . Поэтому оракульное разбиение выигрывает пенализованный объектив лишь при $\lambda_{LB} < \Delta L / \Delta LB_N \approx 3.77$; за этой точкой перелома сбалансированное (и потому доменно-слепое) разбиение получает более высокую оценку. Это прямой, не зависящий от суррогата конфликт между

Таблица 3 — Пенализованный объектив трёх жёстких разбиений на реально обученных пообъектных потерях. Пенализованная оценка —

$$L - \lambda_{LB} LB_N.$$

жёсткое разбиение	u_k (по экспертам)	L	LB_N
оракул [19, 11]	[2.73, 0.51]	−48099	31491
баланс, SGEM [15, 15]	[1.91, 1.90]	−55973	29400
баланс, случайное [15, 15]	[1.77, 2.15]	−57726	29400

балансировкой нагрузки и несбалансированной доменной структурой; он объясняет, почему большое λ_{LB} — надёжно предотвращающее схлопывание — подавляло бы и самую искомую специализацию, поэтому мы работаем существенно ниже точки перелома.