

Поиск архитектуры смеси экспертов с помощью суррогатной модели

Бабкин Пётр Константинович

Научный руководитель: к.ф.-м.н. Бахтеев Олег

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 09.04.01 Информатика и вычислительная техника

2026

Цель исследования

Предложить метод поиска архитектуры для смеси экспертов.

Проблема


При изменении архитектуры эксперта меняется результат роутинга, то есть меняются данные, на которых обучается эксперт.

Предлагаемый метод

Предлагается оценивать качество архитектур каждого из экспертов с помощью суррогатной функции. Суррогатная функция обучается одновременно с оптимизацией назначений экспертов и поиска архитектур.

Схема маршрутизации данных

Каждый элемент данных маршрутизируется одному из экспертов; архитектуры экспертов подбираются под назначенные им кластеры.



Пространство поиска архитектуры смеси экспертов

Архитектуры экспертов

Каждый эксперт — свёрточная нейронная сеть, она задаётся ориентированным ациклическим графом, где каждый узел применяет операцию из множества $\mathcal{O}$. α — вектор выборов операций, по которому восстанавливается архитектура. Смесь из K экспертов задаётся набором $\alpha_1, \dots, \alpha_K$.

Кластеры данных

Данные разбиты на M кластеров: $\mathcal{D} = \mathcal{C}_1 \sqcup \mathcal{C}_2 \sqcup \dots \sqcup \mathcal{C}_M$, $|\mathcal{C}_m|$ — размер кластера m , а $m(n)$ — номер кластера объекта n .

Маршрутизация вектором $\mathbf{r}$

$r_{mk} \in [0, 1]$ — вероятность назначения кластера m эксперту k , $\sum_{k=1}^K r_{mk} = 1$. Они образуют матрицу маршрутизации $\mathbf{R} \in [0, 1]^{M \times K}$; её столбец $\mathbf{r}_k = \mathbf{R}_{:,k}$ задаёт кластеры эксперта k : $I_k = \{ m : \arg \max_{k'} r_{mk'} = k \}$.

Суррогатная модель для оценки качества экспертов

Суррогатная функция $u(\alpha, \mathbf{r})$ предсказывает среднюю по объектам кросс-энтропийную ошибку (loss) архитектуры α , обученной на данных, определяемых вектором $\mathbf{r}$:

$$u : \mathcal{A} \times \{0, 1\}^M \rightarrow \mathbb{R}_{\geq 0},$$

где $\mathcal{A}$ – пространство архитектур, M – число кластеров.

Суррогат выражает пообъектное правдоподобие эксперта:

$$u(\alpha_k, \mathbf{r}_k) \approx -\log p(y_n \mid x_n, \alpha_k, \theta_k, m(n) \in l_k),$$

где θ_k – параметры (веса) эксперта k .

Суррогат представляет собой графовую нейронную сеть, обучаемую на триплетах $(\alpha, \mathbf{b}, \ell)$, где $\mathbf{b} \in \{0, 1\}^M$ – маска подмножества кластеров, ℓ – кросс-энтропийная ошибка архитектуры, обученной на данных, соответствующих $\mathbf{b}$.

Постановка задачи

Максимизация правдоподобия смеси экспертов

$$\prod_{n=1}^N \sum_{k=1}^K p(y_n, m(n) \in I_k \mid x_n, \alpha_k, \theta_k) \rightarrow \max_{\alpha_1, \dots, \alpha_K, \theta_1, \dots, \theta_K},$$

где K – кол-во экспертов, N – кол-во элементов данных, $m(n)$ – номер кластера элемента n . Для k -ого эксперта α_k – архитектура.

Задача поиска архитектуры смеси из K экспертов

$$\sum_{m=1}^M |\mathcal{C}_m| \log \sum_{k=1}^K r_{mk} e^{-u(\alpha_k, \mathbf{r}_k)} \rightarrow \max_{\alpha_1, \dots, \alpha_K, \mathbf{r}_1, \dots, \mathbf{r}_K},$$

где M – число кластеров данных, $|\mathcal{C}_m|$ – размер кластера m , r_{mk} – вероятность назначения кластера m эксперту k , $\mathbf{r}_k = \{r_{mk}\}_{m=1}^M$.

Предлагаемый метод

Обобщенный EM-алгоритм с использованием суррогатной функции.

Algorithm SGEM

Вход: K , данные, кластеризация, $u^{(0)}$ — начальный суррогат
for $t = 0, 1, 2, \dots$ do
 Е-шаг: $q_{mk}^{(t)} \propto r_{mk}^{(t)} e^{-u^{(t)}(\alpha_k^{(t)}, \mathbf{r}_k^{(t)})}$
 М-шаг: $\sum_m |\mathcal{C}_m| \sum_k q_{mk}^{(t)} [\log r_{mk} - u^{(t)}(\alpha_k, \mathbf{r}_k)] \rightarrow \max_{\alpha, \mathbf{R}}$
 S-шаг: добавить актуальные данные, переобучить u
end for

На шаг S суррогат $u^{(t)}$ дообучается и с ростом t стремится к истинной оценке правдоподобия экспертов u_{true} .

Сходимость GEM с суррогатом

L_{true} — функционал из постановки задачи с истинной оценкой правдоподобия u_{true} вместо суррогата.



Теорема (Бабкин, 2026). Пусть $\{\psi^{(t)} = (\alpha^{(t)}, \mathbf{R}^{(t)})\}$ — последовательность, порождаемая алгоритмом SGEM с суррогатами $u^{(t)}$. При достаточной скорости сходимости функционального ряда суррогатных функций к истинной оценке u_{true} и некоторых условиях регулярности выполняется:

- (a) последовательность истинных правдоподобий $\{L_{\text{true}}(\psi^{(t)})\}$ сходится;
- (b) любая предельная точка ψ^* — стационарная точка L_{true} .

Замечание: если ошибка суррогата убывает экспоненциально с показателем $\rho > 1$, то $L_{\text{true}}(\psi^{(T)}) \rightarrow L_{\text{true}}(\psi^*)$ со скоростью $O(T^{1-\rho})$.

Проверка на сэмплированных данных


Сэмплированные данные с двумя явными видами распределений. В пространстве поиска находится 3^7 архитектур.



ЕМ-алгоритм с S-шагом нашёл наилучшее разбиение кластеров на синтетическом датасете и подобрал референсные архитектуры: линейную и использующую ядро RBF.

Смесь CIFAR100 и SVHN

Был составлен датасет путем смешивания CIFAR100 и SVHN в равных пропорциях.



Представители семантических кластеров

Метод	Test Acc.
Random-MoE	0.547 ± 0.029
DARTS $\times K$	0.591 ± 0.009
SGEM (наш)	0.620 ± 0.009
Oracle MoE*	0.633 ± 0.004

Точность MoE
(*оракулу даны метки источника)

Без меток источника SGEM сделал экспертов специалистами по датасетам: один эксперт — по CIFAR-100, другой — по SVHN, превосходя baseline-методы.

Достигнутые результаты

1. Предложена постановка задачи для нахождения архитектуры смеси экспертов
2. Предложен метод SGEM для решения поставленной задачи
3. Доказана теорема о сходимости GEM-алгоритма с адаптивным суррогатом
4. Проведены эксперименты на искусственных и реальных датасетах, где подтверждена эффективность метода

Доклады по теме работы

1. Выступление на конференции МФТИ 2026
2. Смежная работа принята на рецензируемую конференцию AIAI / EAAAI (EANN) 2026
3. Идёт подготовка к подаче работы в журнал