

Поиск архитектуры смеси экспертов с помощью суррогатной модели

Бабкин Пётр

Научный руководитель: к.ф.-м.н. Бахтеев Олег

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 03.04.01 Прикладные математика и физика

2026

План работы

Цель исследования:

Предложить метод поиска архитектуры для смеси экспертов.

Проблема:


При изменении архитектуры эксперта меняется результат роутинга, то есть меняются данные, на которых обучается эксперт.

Предлагаемый метод:

Предлагается оценивать качество архитектур каждого из экспертов с помощью суррогатной функции. Суррогатная функция обучается одновременно с оптимизацией назначений экспертов и поиска архитектур.

Схема работы

Архитектуры экспертов и кластеры данных подбираются для каждого кластера с помощью суррогатной модели u .



Суррогатная модель для оценки качества экспертов

Суррогатная функция $u(\alpha, R)$ предсказывает среднюю по объектам кросс-энтропийную ошибку (loss) архитектуры α , обученной на данных, определяемых вектором R :

$$u : \mathcal{A} \times \{0, 1\}^M \rightarrow \mathbb{R}_{\geq 0},$$

где $\mathcal{A}$ – пространство архитектур, M – число кластеров.

Суррогат выражает пообъектное правдоподобие эксперта (отрицательное лог-правдоподобие):

$$u(\alpha_k, R_k) \approx -\log p(y_n \mid x_n, \alpha_k, \theta_k, m(n) \in C_k).$$

Суррогат представляет собой графовую нейронную сеть, обучаемую на триплетах (α, b, ℓ) , где $b \in \{0, 1\}^M$ – маска подмножества кластеров, ℓ – кросс-энтропийная ошибка архитектуры, обученной на данных, соответствующих b .

Постановка задачи

Максимизация правдоподобия смеси экспертов

$$\prod_{n=1}^N \sum_{k=1}^K p(y_n, m(n) \in C_k \mid x_n, \alpha_k, \theta_k) \rightarrow \max_{\alpha_1, \dots, \alpha_K, \theta_1, \dots, \theta_K},$$

где K – кол-во экспертов, N – кол-во элементов данных, $m(n)$ – номер кластера элемента n . Для k -ого эксперта C_k – множество индексов назначенных ему кластеров, θ_k – параметры, α_k – архитектура.

Задача поиска архитектуры смеси из K экспертов

$$\sum_{m=1}^M |C_m| \log \sum_{k=1}^K r_{mk} e^{-u(\alpha_k, R_k)} \rightarrow \max_{\alpha_1, \dots, \alpha_K, R_1, \dots, R_K},$$

где M – число кластеров данных, $|C_m|$ – размер кластера m , r_{mk} – вероятность назначения кластера m эксперту k , $R_k = \{r_{mk}\}_{m=1}^M$.

Предлагаемый метод

Обобщенный EM-алгоритм с использованием суррогатной функции.

Algorithm SGEM

Вход: K , данные, кластеризация, $u^{(0)}$ — начальный суррогат

for $t = 0, 1, 2, \dots$ do

 Е-шаг: $q_{mk}^{(t)} \propto r_{mk}^{(t)} e^{-u^{(t)}(\alpha_k^{(t)}, R_k^{(t)})}$

 М-шаг: $\sum_m |\mathcal{C}_m| \sum_k q_{mk}^{(t)} [\log r_{mk} - u^{(t)}(\alpha_k, R_k)] \rightarrow \max_{\bar{\alpha}, \bar{R}}$

 S-шаг: добавить актуальные данные, переобучить u

end for

На шаг S суррогат $u^{(t)}$ дообучается и с ростом t стремится к истинной оценке правдоподобия экспертов u_{true} .

Сходимость GEM с адаптивным суррогатом

Теорема. Пусть $\{\theta^{(t)} = (\alpha^{(t)}, r^{(t)})\}_{t=1}^{\infty}$ — последовательность GEM-алгоритма с суррогатом $u^{(t)}$, и выполнены условия: (1) равномерная ограниченность $u_{\text{true}}, \{u^{(t)}\}_{t=1}^{\infty}$, (2) $\sum_{t=1}^{\infty} \varepsilon_t < \infty$ где $\varepsilon_t = \sup |u^{(t)} - u_{\text{true}}|$, (3) на M -шаге F -функция не убывает, (4) $u(\alpha, r)$ непрерывно по второму аргументу $\forall \alpha \in \mathcal{A}$. Тогда:



(a) $\{L_{\text{true}}(\theta^{(t)})\}$ сходится.

(b) Любая предельная точка θ^* является стационарной: $Q_{\text{true}}(\theta; \theta^*) \leq Q_{\text{true}}(\theta^*; \theta^*)$ для всех $\theta \in \Theta$, где $Q_{\text{true}}(\theta; \theta') = \sum_m |\mathcal{C}_m| \sum_k w_{mk}(\theta') [\log r_{mk} - u_{\text{true}}(\alpha_k, R_k)]$ и $w_{mk}(\theta') = q_{mk}^*(\theta')$.

Замечание: если ε_t убывает экспоненциально с показателем $\rho > 1$, то $L_{\text{true}}(\theta^{(T)}) \rightarrow L_{\text{true}}(\theta^*)$ со скоростью $O(T^{1-\rho})$.

Проверка на сэмплированных данных


Сэмплированные данные с двумя явными видами распределений. В пространстве поиска находится 3^7 архитектур.



ЕМ-алгоритм с S-шагом нашёл наилучшее разбиение кластеров на синтетическом датасете и подобрал референсные архитектуры: линейную и использующую ядро RBF.

Смесь CIFAR100 и SVHN

Был составлен датасет путем смешивания CIFAR100 и SVHN в равных пропорциях.



Представители семантических кластеров

Метод	Test Acc.
Random-MoE	0.547 ± 0.029
DARTS $\times K$	0.591 ± 0.009
SGEM (наш)	0.620 ± 0.009
Oracle MoE*	0.633 ± 0.004

Точность MoE (*оракулу даны метки источника)

Без меток источника SGEM сделал экспертов специалистами по датасетам: один эксперт — по CIFAR-100, другой — по SVHN, превосходя baseline-методы.

Достигнутые результаты:

- ▶ Предложена постановка задачи для нахождения архитектуры смеси экспертов с помощью суррогатной функции
- ▶ Предложен метод SGEM для решения поставленной задачи, метод проверен на экспериментах
- ▶ Доказана теорема о сходимости GEM-алгоритма с адаптивным суррогатом

Доклады по теме работы

- ▶ Выступление на конференции МФТИ 2026
- ▶ Смежная работа подана на рецензируемую конференцию AIAI / EAAAI (EANN) 2026