

Поиск архитектуры смеси экспертов с помощью суррогатной модели

Бабкин Пётр

Кафедра интеллектуальных систем ФПМИ МФТИ
Специализация: Интеллектуальный анализ данных
Направление: 03.04.01 Прикладные математика и физика

2026

План работы

Цель исследования:

Предложить метод поиска архитектуры для смеси экспертов.

Проблема:

Адаптация методов поиска архитектуры нейронной сети для задачи поиска архитектуры смеси экспертов неэффективна: сложность поиска растет линейно с числом экспертов.

Предлагаемый метод:

Предлагается оценивать качество архитектур каждого из экспертов с помощью суррогатной функции. Суррогатная функция обучается одновременно с оптимизацией назначений экспертов и поиска архитектур.

Постановка задачи

Максимизация правдоподобия смеси экспертов

$$\prod_{n=1}^N \sum_{k=1}^K p(y_n, n \in C_k \mid x_n, \alpha_k, \theta_k) \rightarrow \max_{\alpha_1, \dots, \alpha_K, \theta_1, \dots, \theta_K},$$

где K – кол-во экспертов, N – кол-во элементов данных. Для k -ого эксперта C_k – его индексы данных, θ_k – параметры, α_k – архитектура.


Задача поиска архитектуры смеси из K экспертов

$$\prod_{n=1}^N \sum_{k=1}^K r_{nk} u(\alpha_k, R_k) \rightarrow \max_{\alpha_1, \dots, \alpha_K, R_1, \dots, R_K},$$

где r_{nk} – вероятность назначения элемента n эксперту k , $R_k = \{r_{nk}\}_{n=1}^N$, $u(\alpha_k, R_k)$ – суррогатная функция, оценивающая качество архитектуры α_k на данных R_k .

Схема работы

Архитектуры экспертов и кластеры данных подбираются для каждого кластера с помощью суррогатной модели u .



Суррогатная модель для оценки качества экспертов

Суррогатная функция $u(\alpha, R)$ предсказывает валидационную точность архитектуры α на данных, определяемых вектором R :

$$u : \mathcal{A} \times \{0, 1\}^N \rightarrow \mathbb{R},$$

где $\mathcal{A}$ – пространство архитектур.

Суррогат представляет собой нейронную сеть или Гауссовский процесс, который обучается на триплетах (α, b, a) , где $b \in \{0, 1\}^N$, a – точность архитектуры, обученной на данных, соответствующих b .

Предлагаемый метод

Обобщенный EM-алгоритм с использованием суррогатной функции.

Algorithm SGEM

- 1: **Вход:** K , данные, кластеризация, $u^{(0)}$ — начальный суррогат
 - 2: **for** $t = 0, 1, 2, \dots$ **do**
 - 3: **Е-шаг:** $q_{mk}^{(t)} \sim r_{mk}^{(t)} u^{(t)}(\alpha_k^{(t)}, R_k^{(t)})$
 - 4: **М-шаг:** $\sum_m \sum_k q_{mk}^{(t)} \log(r_{mk} u^{(t)}(\alpha_k, R_k)) \rightarrow \max_{\bar{\alpha}, \bar{R}}$
 - 5: **С-шаг:** добавить актуальные данные, переобучить u
 - 6: **end for**
-

Градиентный метод: вместо Е/М-шагов — прямая градиентная оптимизация r и α .

Сходимость GEM с адаптивным суррогатом

Теорема. Пусть $\{\theta^{(t)} = (\alpha^{(t)}, r^{(t)})\}_{t=1}^{\infty}$ — последовательность GEM-алгоритма с суррогатом $u^{(t)}$, и выполнены условия: (1) равномерная ограниченность u_{true} и $\{u^{(t)}\}_{t=1}^{\infty}$, (2) $\sum_{t=1}^{\infty} \varepsilon_t < \infty$ где $\varepsilon_t = \sup |\log u^{(t)} - \log u_{\text{true}}|$, (3) на M -шаге $\mathcal{F}$ -функция не убывает, (4) $u(\alpha, r)$ непрерывно по второму аргументу $\forall \alpha \in \mathcal{A}$. Тогда:

(a) $\{L_{\text{true}}(\theta^{(t)})\}$ сходится.

(b) Любая предельная точка θ^* является стационарной: $Q_{\text{true}}(\theta; \theta^*) \leq Q_{\text{true}}(\theta^*; \theta^*)$ для всех $\theta \in \Theta$, где $Q_{\text{true}}(\theta; \theta') = \sum_m \sum_k w_{mk}(\theta') \log(r_{mk} u_{\text{true}}(\alpha_k, R_k))$ и $w_{mk}(\theta') = q_{mk}^*(\theta')$.

Замечание: если ε_t убывает экспоненциально с показателем $\rho > 1$, то $L_{\text{true}}(\theta^{(T)}) \rightarrow L_{\text{true}}(\theta^*)$ со скоростью $O(T^{1-\rho})$.

Цели вычислительного эксперимента

Показать применимость метода



- ▶ Проверить семантическую кластеризуемость реальных датасетов.
- ▶ Показать, что существует разброс точностей архитектур на разных кластерах данных.

Проверить эффективность работы метода

- ▶ Проверить эффективность методов для нахождения разбиения и архитектур на синтетических данных.



Применимость метода

Существует разброс точности архитектуры по кластерам.



Разброс в среднем составляет 2%. Минимум он составляет 1,2%.

Эффективность работы



Метод	Split	Совпадение	MoE acc
SGEM	[7, 13]	20/20	95.6%*
Единая архитектура	—	—	~75%

* С референсными архитектурами (linear + RBF) на найденном split.

Заключение

Достигнутые результаты:

- ▶ Предложена постановка задачи для нахождения архитектуры смеси экспертов с помощью суррогатной функции
- ▶ Предложен метод SGEM для решения поставленной задачи
- ▶ Доказана теорема о сходимости GEM-алгоритма с адаптивным суррогатом
- ▶ В экспериментах алгоритм показал свою эффективность

Дальнейшая работа

- ▶ Провести эксперименты на реальных датасетах (CIFAR, ImageNet)
- ▶ Сравнить с конкурирующими методами (AutoMoE, DSR)
- ▶ Исследовать масштабируемость метода на большое число экспертов

- ▶ Chen Z. et al. Towards understanding mixture of experts in deep learning // arXiv:2208.02813, 2022.
- ▶ Jiang L. et al. AutoMoE: Heterogeneous mixture-of-experts with adaptive computation // ACL 2023.
- ▶ Piwko J. et al. Divide, specialize, and route: a new approach to efficient ensemble learning // arXiv:2506.20814, 2025.
- ▶ Dempster A.P. et al. Maximum likelihood from incomplete data via the EM algorithm // JRSS-B, 1977.
- ▶ Wu C.F.J. On the convergence properties of the EM algorithm // Annals of Statistics, 1983.